

Predicción de resultados y Simulación Monte Carlo del Mundial FIFA 2026 utilizando Machine Learning

Castillo Hernández, Monica Castillo
mg16039@ues.edu.sv

Facultad de Ingeniería y Arquitectura, Universidad de El Salvador.

Abstract—Este trabajo presenta los resultados obtenidos en el desarrollo y entrenamiento de un algoritmo de predicción de resultados de partidos internacionales de fútbol y la simulación del mundial FIFA 2026 utilizando modelos de Machine Learning de Regresión Logística y XGBoost, haciendo uso de variables derivadas como la diferencia de porcentaje de victorias, promedios de goles anotados y ventaja o localía neutral, seguidamente se aplicó la validación cruzada para evaluar la estabilidad y capacidad de generalización de los modelos.

Posteriormente, estas probabilidades fueron utilizadas en una simulación Monte Carlo, de 10,000 torneos completos del Mundial FIFA 2026, permitiendo estimar las probabilidades de obtener la victoria por cada selección participante. Estos resultados, aunque la predicción de empates continúa siendo un desafío para el algoritmo, debido a la naturaleza altamente variable del fútbol, la simulación probabilística estocástica permite generar estimaciones razonables del desempeño de las selecciones nacionales.

Finalmente, el modelo demuestra la utilidad de combinar Machine Learning y la simulación estocástica para el análisis predictivo en competiciones deportivas.

Keywords—Machine Learning, Dataset, Monte Carlo, Regresión Logística, scikit-learn, XGBoost.

I. OBJETIVO

La predicción de los resultados en campeonatos deportivos, se ha convertido en una de las aplicaciones relevantes de Machine Learning, debido a la gran disponibilidad de datos históricos. En este proyecto se desarrolla un pipeline de Machine Learning capaz de predecir la probabilidad de que una selección nacional gane partidos internacionales y mediante una simulación Monte Carlo del , Mundial FIFA 2026 se estiman las probabilidades de que cada una de las 48 selecciones nacionales participantes obtengan el campeonato mundial de fútbol.

II. OBTENCIÓN Y PREPARACIÓN DE DATOS

Para el Desarrollo del Proyecto, se utilizó un dataset histórico de partidos internacionales de fútbol[1], el cual contiene información sobre partidos de selecciones nacionales, la cantidad de goles anotados por cada selección, localía si ha jugado como visitante o local, y la sede neutral.

Inicialmente el dataset contaba con una cantidad de 49,329 registros, cada uno representa un partido jugado.

Columna	Descripción del Dataset		
	Tipo de dato	Cantidad de datos	Descripción
Date	Object	49,329	Fecha en la que se jugó el partido
Home_team	Object	49,329	Nombre del equipo local
Away_team	Object	49,329	Nombre del equipo visitante
Home_score	Float(64)	49,257	Goles anotados por el equipo local
Away_score	Float(64)	49,257	Goles anotados por el equipo visitante
Tournament	Object	49,329	Nombre del torneo en el que se jugó el partido
City	Object	49,329	Ciudad donde se jugó el partido
Country	Object	49,329	País donde se jugó el partido
Neutral	Bool	49,329	Indica si la cancha donde se jugó el partido, pertenece o no al equipo local.

Posteriormente, se realizó una limpieza en los datos, quitando nulos, cambiando tipos de datos, normalizando los nombres las selecciones y filtrando los partidos de un total de 336 naciones encontradas, conservando únicamente los encuentros disputados de las 48 selecciones participantes del mundial FIFA 2026, obteniendo un conjunto final de 75,501 partidos, garantizando la consistencia entre la fuente de datos y evitando duplicados o entidades no deseadas.

Durante la etapa de preparación de datos, se construyó una variable denominada “target”, la cual se encarga de representar el resultado del partido, clasificándolo como 0: victoria local, 1: empate, 2 victoria visitante, representando una consistencia de en los datos, lo que nos indica que el dataset, preserva las características estadísticas:

Target	Dataset antes del filtrado de los partidos		
	Ganador	Count	% partidos ganados
0	Local	24,130	48.99%
1	Empate	13,925	28.27%
2	Visitante	11,202	22.74%

Target	Datos después del filtrado de las 48 selecciones		
	Ganador	Count	% partidos ganados
0	Local	3,479	46.38%
1	Empate	2,124	28.31%
2	Visitante	1,898	25.30%

Con estos resultados, se logró observar que el dataset presenta un ligero desbalance, con una mayor frecuencia de victorias si el equipo juega como local, lo cual sugiere la existencia de ventaja de localía incluso en partidos internacionales, no presenta desbalance extremo, ya que presenta una distribución moderada de clases.

Se verificó la consistencia de los datos al momento de filtrar y comparar el dataset original observando que no hay mayor porcentaje de variación, y se preparó la información necesaria para la construcción de variables derivadas utilizadas en los modelos de machine learning.

III. INGENIERÍA DE CARACTERÍSTICAS

Con el objetivo de mejorar la capacidad predictiva de los modelos de machine learning, se construyeron variables derivadas a partir de las estadísticas históricas de cada selección nacional.

Inicialmente se calcularon métricas generales del desempeño de cada equipo:

- winrate: Porcentaje de victorias.
- avg_goals: Promedio de goles anotados por partido.
- matches: Cantidad total de partidos disputados.

Posteriormente, estas métricas fueron utilizadas para construir variables comparativas entre los equipos, locales y visitantes en cada partido:

- winrate_diff: Diferencia entre el porcentaje de victorias de ambos equipos.
- goals_diff: Diferencia entre el promedio de goles anotados.
- neutral: Variable binaria que indica si el partido fue disputado en sede o neutral.
- abs_winrate_diff: valor absoluto de la diferencia de porcentaje de victorias.
- abs_goals_diff: Valor absolute de la diferencia de goles promedio.
- home_stronger: Variable binaria que indica si el equipo local posee mejores estadísticas históricas.
- strength_combined: Combinación multiplicativa entre diferencia de victorias y diferencia ofensiva.
- match_balance: Indicador del equilibrio competitivo entre ambas selecciones.

Estas características permitieron representar numéricamente la diferencia de rendimiento entre selecciones nacionales, lo cual facilitó el entrenamiento de los modelos predictivos.

IV. MODELOS DE MACHINE LEARNING.

Para la predicción de resultados de los partidos internacionales, se implementaron modelos supervisados de clasificación multiclase, utilizando la librería scikit-learn [2]

El conjunto de datos se dividió 80-20, siendo el 80% en datos de entrenamiento y el 20 los datos para la evaluación, aplicando la técnica del train test Split, permitiendo así evaluar la capacidad de generalización de los modelos sobre datos no utilizados durante el entrenamiento.

Las variables de entrada estuvieron compuestas por las características generadas durante la etapa III, mientras que la variable objetivo representó el resultado final del partido como 0: victoria equipo local, 1: empate o 2: victoria equipo visitante.

A. Regresión Logística.

La regresión logística [3] fue utilizada como modelo base, debido a su simplicidad, interpretabilidad y bajo costo computacional, este modelo permitió estimar probabilidades para múltiples clases mediante funciones logísticas, siendo ampliamente utilizado en problemas de clasificación supervisada.

Para asegurar la convergencia del entrenamiento, se configuró el máximo de iteraciones en 1,000 iteraciones, de las cuales, solo fueron necesarias 32 para converger, lo cual indica estabilidad en la optimización y adecuada separación lineal aproximada en el espacio de características.

B. XGBoost

Adicionalmente, se implementó un modelo basado en XGBoost [4], el cual utiliza técnicas de gradiente para combinar múltiples árboles de decisión y con ello mejorar la capacidad predictiva.

Fue seleccionado debido a su capacidad para capturar relaciones no lineales entre variables y manejar interacciones complejas entre características deportivas.

Ambos modelos fueron entrenados utilizando las mismas variables de entrada con el objetivo de comparar su desempeño predictivo y estabilidad estadística.

V. EVALUACIÓN DE MODELOS

Para evaluar el desempeño de los modelos entrenados, se utilizaron métricas de clasificación multiclase, incluyendo la precisión, sensibilidad, F1-score y log loss

Además, se aplicó la validación cruzada utilizando 5 particiones con el objetivo de medir la estabilidad y capacidad de generalización de los modelos sobre diferentes sub conjuntos de datos.

Los resultados obtenidos, muestran que la Regresión Logística presenta un desempeño superior y mas estable en comparación con XGBoost, bajo las variables construidas en este proyecto, obteniendo los resultados:

Modelo	Validación cruzada	
	Log loss	Accuracy
Regresión Logística	1.016	0.5107
XGBoost	1.021	0.5034
Diferencia	1.037	0.0073

El modelo de regresión logística obtuvo un log loss ligeramente menor en comparación con XGBoost, lo que indica una mejor calibración de probabilidades en este conjunto de datos.

Además, obtenemos los datos de la evaluación del modelo Regresión Logística:

Variable	Métricas Regresión Logística			
	Precisión	Recall	F1-score	Support
0 – gana local	0.54	0.84	0.66	690
1 – Empate	0.00	0.00	0.00	363
2 – gana visitante	0.47	0.44	0.45	448
Accuracy			0.52	1501
Macro avg	0.34	0.43	0.37	1501
Weighted avg	0.39	0.52	0.44	1501

Y los datos obtenidos de la evaluación del modelo XGBoost:

Variable	Métricas XGBoost			
	Precisión	Recall	F1-score	Support
0 – gana local	0.54	0.80	0.64	690
1 – Empate	0.30	0.06	0.10	363
2 – gana visitante	0.48	0.43	0.40	448
Accuracy			0.51	1501
Macro avg	0.44	0.43	0.40	1501
Weighted avg	0.46	0.51	0.45	1501

Observamos que, aunque en la evaluación del modelo entrenado XGBoost, tiene una mejor respuesta al empate, que el modelo de Regresión Logística que no predice los empates, los valores del accuracy y el Log loss de Regresión Logística vs los valores de XGBoost, son ligeramente mayores.

Por lo cual, se selecciona el modelo de Regresión Logística por su mayor estabilidad y ligera mejor calibración probabilística.

VI. SIMULACIÓN MONTE CARLO

Para estimar la probabilidad de que cada selección nacional gane el Mundial FIFA 2026, se implementó una simulación Monte Carlo basada en el modelo de Machine Learning previamente entrenados y elegido.

En cada iteración de la simulación, se generó un torneo completo de eliminación directa entre las 48 selecciones participantes. Los resultados de cada partido fueron determinados utilizando las probabilidades de victoria estimadas por el modelo de Regresión Logística.

Este proceso se repitió 10,000 veces con el objetivo de aproximar la distribución de resultados posibles del torneo, observándose una distribución estable de resultados, las selecciones con mayor probabilidad de campeonato fueron

aquellas con mejor desempeño histórico y mayor tasa de victoria en el dataset, siendo la métrica principal:

$$P(\text{campeón}) = \frac{\text{número de veces campeón}}{\text{número total de simulaciones}}$$

Al finalizar las simulaciones, se contabilizó el número de veces que cada selección resultó campeona, obteniendo así una estimación empírica de la probabilidad de campeonato.

VII. RESULTADOS FINALES

Después de ejecutar 10,00 veces las simulaciones Monte Carlo del Mundial FIFA 2026, utilizando las probabilidades generadas por el modelo de regresión logística, se obtuvo una distribución de probabilidades de campeonato para las 48 selecciones participantes.

No	País	Métricas			
		Prob de campeón	Histórico de partidos ganados	Prom histórico de goles	Total de partidos históricos utilizados para calcular estadísticas
1	Brazil	14.95%	58.1	1.97	673
2	Germany	11.64%	51.58	1.99	539
3	England	8.27%	47.62	1.92	525
4	Spain	8.02%	50.78	1.78	386
5	Argentina	7.11%	49.42	1.77	694
6	Netherlands	4.88%	41.27	1.87	504
7	France	4.56%	45.98	1.63	498
8	Mexico	3.49%	43.64	1.54	495
9	Sweden	3.33%	38.54	1.71	467
10	Belgium	2.85%	37.6	1.65	500
11	Austria	2.74%	39.18	1.64	342
12	Australia	2.62%	40.84	1.41	311
13	Croatia	2.07%	38.6	1.39	171
14	Iran	1.9%	40.89	1.19	225
15	Uruguay	1.78%	37.66	1.43	608
16	Portugal	1.48%	38.08	1.35	344
17	South Korea	1.43%	38.08	1.23	386
18	Morocco	1.42%	38.02	1.18	263
19	Czech Republic	1.35%	36.36	1.31	132
20	Japan	1.12%	34.95	1.3	329
21	Scotland	1.05%	34.65	1.32	381
22	Algeria	0.92%	35.53	1.14	228
23	Turkey	0.89%	34.58	1.18	240
24	Ghana	0.84%	34.07	1.26	226
25	Côte d'Ivoire	0.82%	34.06	1.27	229
26	United States	0.82%	34.07	1.22	405

No	País	Descripción del Dataset			
		<i>Prob de campeón</i>	<i>Histórico de partidos ganados</i>	<i>Prom histórico de goles</i>	<i>Total de partidos históricos utilizados para calcular estadísticas</i>
27	South Africa	0.77%	32.94	1.22	170
28	Egypt	0.77%	35.07	1.1	288
29	Colombia	0.72%	36.26	1.15	364
30	Switzerland	0.67%	29.12	1.36	443
31	Haiti	0.6%	31.3	1.13	115
32	Tunisia	0.49%	32.04	1.1	284
33	Iraq	0.47%	32.3	1.04	257
34	Senegal	0.43%	33.95	0.99	215
35	Norway	0.39%	24.78	1.26	343
36	Saudi Arabia	0.37%	30.25	1.04	281
37	Paraguay	0.32%	25.32	1.07	474
38	Canada	0.31%	27	0.99	200
39	Uzbekistan	0.25%	27.12	1.04	118
40	Qatar	0.25%	26.48	0.98	219
41	Curaçao	0.18%	20	1.1	60
42	Ecuador	0.16%	22.6	0.98	323
43	New Zealand	0.1%	16.56	0.94	151
44	Jordan	0.1%	22.36	0.86	161
45	Bosnia and Herzegovina	0.09%	16.83	0.93	101
46	Congo DR	0.09%	17.19	1	128
47	Panama	0.09%	12.75	0.76	149
48	Cape Verde	0.03%	12.28	0.6	57

Los resultados muestran que las selecciones con mejor desempeño histórico dentro del dataset presentan mayores probabilidades de obtener el campeonato mundial. Particularmente Brasil y Alemania obtuvieron las probabilidades más altas de campeonato debido a sus elevados porcentajes históricos de victorias.

Asimismo, se observa que las selecciones históricamente fuertes mantienen una ventaja estadística significativa dentro de la simulación, aunque el componente probabilístico permite la aparición de resultados inesperados y variabilidad competitiva entre torneos simulados. Finalmente, el proyecto demuestra cómo la combinación de Machine Learning y simulación probabilística Monte Carlo puede utilizarse para modelar competiciones deportivas complejas a partir de datos históricos.

VIII. CONCLUSIONES

El proyecto se desarrolló un pipeline de Machine Learning para la predicción de resultados de partidos internacionales y la simulación probabilística del Mundial FIFA 2026 mediante el método de simulación Monte Carlo.

A partir de datos históricos de selecciones nacionales, fue posible construir variables representativas del rendimiento de cada equipo, permitiendo entrenar modelos capaces de estimar probabilidades de victoria, empate y derrota.

Los resultados obtenidos muestran que la Regresión Logística presentó un desempeño ligeramente superior y más estable en comparación con XGBoost bajo las características utilizadas en este proyecto.

Se observó que la predicción de empates continúa siendo una de las principales dificultades debido a la naturaleza altamente variable del fútbol.

Mediante la simulación Monte Carlo, se permitió modelar miles de escenarios posibles del torneo, generando probabilidades empíricas del mundial para casa selección participante, con esto se demuestra como las técnicas de ML y simulación estocástica pueden utilizarse para analizar competiciones deportivas complejas a partir de información histórica.

REFERENCES

[1] M. Jüriso, “International football results from 1872 to 2024,” GitHub repository. [En línea]. Disponible en: [martj42/international_results](https://github.com/martj42/international_results). [Accedido: 21-may-2026].

[2] Scikit-learn Developers, “Scikit-learn: Machine Learning in Python,” [En línea]. Disponible en: <https://scikit-learn.org/stable/>. [Accedido: 20-may-2026].

[3] Scikit-learn Developers, “Logistic Regression,” [En línea]. Disponible en: https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression. [Accedido: 24-may-2026]. Otro modelo

[4] XGBoost Developers, “XGBoost Documentation,” [En línea]. Disponible en: <https://xgboost.readthedocs.io/>. [Accedido: 24-may-2026].